

锂离子电池快充策略对寿命衰减的影响建模与优化

摘要

快充策略在缩短锂离子电池补能时间的同时会加速容量衰减，如何刻画快充策略与寿命衰减的定量关系并兼顾二者优化，是新能源汽车与储能系统的关键问题。本文基于 MIT-Stanford 锂离子电池循环老化数据集（49 块电池、9350 条循环记录、9 种两阶段快充策略），围绕快充策略参数（ C_1 、 Q_1 、 C_2 ）对寿命衰减的影响，建立了从数据清洗、统计推断、寿命预测到多目标优化的完整流程，每一步都走留出验证、用 bootstrap 量化不确定性，全程可复现。

针对问题一：完成最小干预的数据清洗（修复 3 处异常），以两阶段函数型曲线模型为主模型、样条混合与多项式混合为候选，按整块电池留一验证（LOBO）估计各策略 SOH 曲线，主模型 LOBO RMSE 为 0.004325。三种模型的策略排序一致；以电池级外推 T_{80} 为寿命主口径，典型长寿命策略为 3_6C-80PER_3_6C、4_8C_80PER_4_8C（新）与 5C_67PER_4C，短寿命为 3_7C_31PER_5_9C、4_8C_80PER_4_8C 与 80PER_3_6C，SOH200 排名仅作参考；经 Holm 校正后无确证显著的策略对，但 20 组未校正 bootstrap 区间不跨零。

针对问题二：引入低维应力坐标（总电流应力 J 、高 SOC 加权应力 H 及高 SOC 分位应力 J_{high} ）建立约束退化混合模型。策略间末段退化率存在全局差异（诊断性尾部比例 5×10^{-5} ），高 SOC 分位应力与退化方向一致且 bootstrap 系数 100% 为正；但受固定协议组、样本量与方差不等限制，该诊断非确证性检验，选择校正后尾部比例为 0.065， C_1, Q_1, C_2 的独立因果效应还不能当作结论。

针对问题三：因部署时固定提供 150 个观测循环，按 $L = 150$ 外层 LOBO 冻结线性外推模型 $P1_linear$ ，策略等权 RMSE 为 0.000617；轨迹岭模型 C_ridge 作为多长度综合稳健性敏感性保留。给出 9 块测试电池 151–200 循环预测与保守点区间，80% 寿命仅作参考外推。

针对问题四：采用观测策略离散 Pareto 与整块电池 bootstrap。若优先缩短时间并接受约 0.13% 退化，推荐 5_3C_54PER_4C（ $C_1 = 5.3, Q_1 = 54\%, C_2 = 4.0$ ）：较长寿命基准缩短约 24% 时间、退化仅增约 0.13 个百分点；5C_67PER_4C 因成对 bootstrap 区间跨零而保留为近似并列敏感性项而非共同推荐。连续参数响应面因 oracle 压力测试失败被淘汰。

跨问题一致结论：充电策略标签与 SOH 退化相关，早期 SOH 动态是短期预测的主要信息，但稀疏混杂设计使结论须限制在已观测策略内，所有寿命终点均为外推估计。

关键字：锂离子电池 快充策略 函数型曲线 混合效应模型 留一验证 Pareto 优化

一、问题重述

1.1 问题背景

锂离子电池的快速充电能够显著缩短补能时间、提高使用便利性，但过高的充电电流会导致电池内部极化增强、热效应加剧与副反应加速，从而加快容量衰减、缩短电池寿命^[4]。电池寿命通常以健康状态 SOH 表征，定义为当前可用容量与初始容量之比，本题统一以 80% SOH 作为寿命终止阈值。

影响电池寿命的两个主要指标为充电倍率（C-rate）与荷电状态 SOC。不同 SOC 区间内电池对充电电流的敏感程度不同：在低 SOC 区间采用较大电流可能有助于缩短充电时间，而在中高 SOC 区间继续采用高倍率充电则可能加剧老化。本题采用 MIT-Stanford 公开数据集（49 块 A123 18650 磷酸铁锂电池，额定容量 1.1 Ah），各电池放电策略一致，差异体现在两阶段快充策略：先以 C_1 倍率从 0% 充电至 Q_1 ，再以 C_2 倍率从 Q_1 充电至 80%，最后以 1C 恒流-恒压（CC-CV）充至满电。

1.2 问题要求

- (1) 整理数据，分析不同快充策略下的寿命分布，提取并对比典型长寿命与短寿命策略；
- (2) 分析充电策略参数（ C_1, Q_1, C_2 ）对寿命衰减的影响，检验差异显著性及参数影响程度；
- (3) 基于 9 块测试电池截至第 150 循环的数据建立寿命预测模型，预测第 151–200 循环 SOH 并外推寿命，评价精度及早期数据长度的影响；
- (4) 设计兼顾充电时间与寿命衰减的策略优化方法，给出推荐策略并与典型策略对比。

1.3 数据特征

本数据集的结构有几处需要特别留意。9350 条循环记录是 49 块电池的重复测量，循环之间并不独立，显著性检验与交叉验证必须按整块电池划分；9 种策略里 C_1, Q_1, C_2 联合变化，参数坐标高度相关，还夹着新旧结构与数据批次混杂；数据只观测到第 200 循环、SOH 最低约 0.95，没有电池达到 80% 终点，寿命终点只能外推^[1]。

二、问题分析




图 1 四问方法链：数据清洗 → 寿命描述 (Q1) → 参数效应 (Q2)，Q2 应力同时作为 Q3 早期特征；Q1 的策略级充电时间与 SOH、Q2 的退化响应、Q3 的 T80 共同支撑 Q4 策略优化，贯穿留一验证与 bootstrap 不确定性量化

2.1 问题一的分析

对策略寿命的比较，本文最后落到函数型/混合效应模型上——总体退化、策略差异、电池个体差异分层刻画，选模和不确定性评估都按整块电池来做。这套取舍对应着数据本身的三层麻烦：9350 条循环记录其实是 49 块电池的重复测量，循环间并不独立，混在一起统计会把方差明显低估；每类策略只有 2-7 块电池，单块噪声不小；又没有一块电池跑到 80% 的寿命终点，“寿命”只能由早期 SOH 趋势外推刻画。

2.2 问题二的分析

策略参数与寿命的关系，本文没有去分解 C_1, Q_1, C_2 的独立效应，而是用低维应力坐标加混合效应模型来回答。不是不想分——9 种策略只有 7 个互不相同的参数组合，三个参数联合变化，还夹着新旧结构与数据批次，独立效应在原理上就分不开。直接做三参数线性回归会耗尽自由度，随机森林样本量不够也分离不出稳定效应。换个角度构造有物理含义的应力指标（总应力、高 SOC 应力），把参数带来的退化与电池本身的差异分开，显著性交给置换检验这类重采样。协议组固定、样本量和方差不齐，置换结果只能算诊断性证据，够不上严格 p 值^[6, 4]。

2.3 问题三的分析

151–200 循环的 SOH 怎么预测，本文选择了六模型对比、在固定 150 循环窗口下严格留一验证的路线，最后冻结 $P1_linear$ 。这条路线是被信息量逼出来的：只有前 150 个循环，早期衰减又慢，信号几乎淹没在噪声里。ARIMA 假设序列平稳，跟单调衰减对不上；深度学习在 40 块电池上过拟合；纯曲线外推对拟合起点敏感，结果差得很大。预测区间用外层残差校准，寿命终点单独作为情景外推，不跟短期误差混在一起^[7, 10]。

2.4 问题四的分析

兼顾充电时间和寿命衰减的推荐，本文就在 9 个已测策略里做离散 Pareto，用 bootstrap 看前沿稳不稳定，再给条件推荐。搜索连续参数空间的念头被样本量堵死了——只有 9 个实测策略，NSGA-II 这类算法会在没测过的组合上凭空造出最优解；加权求和又把两个不同量纲的目标硬加在一起，权重主观。连续响应面交叉验证不过关，干脆不用^[2, 3]。

三、模型假设

- (1) 假设电池容量测量误差为随机噪声，单次异常尖峰不代表真实寿命改善，可作为数据质量异常修复；
- (2) 假设各电池放电策略一致，电池间差异来源于充电策略与个体制造差异；
- (3) 假设 SOH 在观测窗口内近似平滑，可用函数型/混合效应模型描述，且平均 SOH 随循环单调下降；
- (4) 假设充电时间主要由两阶段恒流决定，恒压尾段与结构/批次影响作为经验项；
- (5) 假设推断单位是整块电池而非循环记录，显著性检验与重采样均按电池/策略聚类；
- (6) 忽略温度、内阻的精细机理，仅将其作为观测协变量^[8]。

四、符号说明

表 1 符号说明

符号	含义	单位
C_1	第一阶段充电倍率（低 SOC 区， $0 \sim Q_1$ ）	—
Q_1, q	阶段切换 SOC； $q = Q_1/100$	%
C_2	第二阶段充电倍率（中高 SOC 区， $Q_1 \sim 80\%$ ）	—
J	总电流应力 $qC_1 + (0.8 - q)C_2$	—
H	高 SOC 加权应力 $\frac{1}{2}[C_1q^2 + C_2(0.8^2 - q^2)]$	—
J_{high,s_0}	SOC 高于 s_0 区间的倍率应力	—
T_0	理想恒流充电时间	min
L	早期观测数据长度	循环
b_i	第 i 块电池的基线容量	Ah
$\text{SOH}_{i,t}$	第 i 块电池第 t 循环的健康状态	—
r_i	第 i 块电池的退化率（对数尺度）	—
D_p	策略 p 的 200 循环退化量	—
T_p	策略 p 的平均充电时间	min

五、数据预处理

5.1 原始数据核对

原始数据含电池级摘要表（49 行）与循环级时序表（9350 行）。核对确认 40 块完整电池包含第 1–200 循环，9 块测试电池（ $\text{prediction_test} = 1$ ）仅含第 1–150 循环；共 9 种充电策略。

5.2 异常识别与可审计修复

对循环数据逐电池检测局部异常：容量采用 ± 5 循环邻域的稳健 z 分数与相对偏差判定，内阻以 $IR \leq 0$ 判定为物理无效。修复采用相邻有效循环线性插值，共 3 处（表 2），原始值与修复标记全部保留。

表 2 数据清洗修复记录

电池	循环	变量	原始值	修复值	依据
1	12	容量/Ah	1.539054	1.074304	稳健 z 与相对偏差双超限
2	12	内阻/ Ω	0	0.016869	内阻必须为正
3	12	内阻/ Ω	0	0.016683	内阻必须为正




图 2 数据清洗前后对照（容量尖峰与零内阻修复）

电池 41 存在初始 SOH 基线偏低（约 0.953），判断为批次/定义差异而非单点异常，予以保留并增加相对 SOH 辅助指标；策略 80PER_3_6C 的 C_1 缺失（单阶段策略），不猜测填补，仅进入类别比较。清洗后保留全部 49 块电池、9350 条记录。

六、问题一模型的建立与求解

6.1 两阶段函数型曲线模型

将每块电池的 SOH 视为关于循环数的函数曲线，令 $x = t/200$ ，以三次样条基函数

$$B(x) = [1, x, x^2, x^3, (x - 0.25)_+^3, (x - 0.50)_+^3, (x - 0.75)_+^3] \quad (1)$$

建立两阶段函数型曲线主模型：先对每块电池的 SOH 曲线做三次样条岭平滑，再在策略内等权平均电池系数得到策略级曲线，即

$$\boxed{\text{SOH}_{i,t} = \mathbf{B}(x_t)^\top (\gamma + \gamma_{p(i)}) + \varepsilon_{i,t}} \quad (2)$$

其中 γ 为总体退化系数， $\gamma_{p(i)}$ 为策略 $p(i)$ 的偏离，按每块电池等权而非每条循环记录等权。经扩展超参数网格（含 λ_{random} 与 λ_{curve} 两个惩罚项）留一验证，最终选中 $\lambda_{\text{curve}} = 0$ ，即退化为无正惩罚的函数型曲线解。以样条混合（`spline_mixed`，带电池随机截距与随机斜率）与多项式混合（`polynomial_mixed`）为候选对照。模型用 40 块完整电池按整块电池留一验证（LOBO）评价，策略级指标以整块电池 `bootstrap` 估计标准误与区间。主模型训练残差的一阶自相关约为 0.645，说明平滑后仍存在循环内序列相关，故不确定性统一用整块电池 `bootstrap` 处理。

6.2 模型选择

三个候选模型的 LOBO RMSE 极其接近（表 3），两阶段函数型曲线以 0.004325 略优，选为主模型；且三模型对第 200 循环 SOH 的策略排序一致，说明排序稳健。

表 3 问题一候选模型比较（LOBO）

模型	平均电池 RMSE	平均电池 MAE	最差策略 RMSE	选定
<code>polynomial_mixed</code>	0.004394	0.004071	0.018335	否
<code>spline_mixed</code>	0.004342	0.004036	0.018332	否
<code>functional_curve</code>	0.004325	0.004026	0.018332	是




图 3 各策略 SOH 曲线（主模型拟合）




图 4 三候选模型 LOBO 误差对比

6.3 策略寿命分布与典型策略识别

由于数据无 80% 终点，以电池级外推 T_{80} （SOH 降至 80% 所需循环数，估计方法见 6.5 节）为循环寿命主指标，SOH200 与前 200 循环损失仅作辅助。9 种策略按 T_{80} 中位数降序排列见表 4： T_{80} 中位数分布在 1000.8 ~ 8537.6 循环之间，辅助指标 SOH200

分布在 0.9659 ~ 0.9967 之间。新结构 4_8C 按 SOH200 排名第 6、按 T_{80} 居第 2，故寿命分组以 T_{80} 为准。

表 4 各策略寿命指标（按 T_{80} 中位数降序；SOH200 与损失仅辅助）

排名	策略	T_{80} 中位数/cycle	bootstrap 95% 区间	SOH200（辅助）	前 200 循环损失（辅助）
1	3_6C-80PER_3_6C	8537.6	[4153.6, 10721.6]	0.9967	0.0004
2	4_8C_80PER_4_8C（新）	7362.2	[5672.2, 9557.5]	0.9873	0.0013
3	5C_67PER_4C（新）	6434.0	[5875.1, 8293.4]	0.9955	0.0019
4	5_3C_54PER_4C（新）	6159.2	[5624.9, 8872.3]	0.9954	0.0017
5	5_6C_36PER_4_3C（新）	5654.3	[4422.4, 7579.5]	0.9947	0.0029
6	5_6C_19PER_4_6C（新）	5614.8	[4558.5, 6359.1]	0.9939	0.0036
7	80PER_3_6C	4672.7	[1081.6, 5992.9]	0.9805	0.0174
8	4_8C_80PER_4_8C	1595.1	[1577.2, 2986.8]	0.9855	0.0101
9	3_7C_31PER_5_9C（新）	1000.8	[914.5, 1351.5]	0.9659	0.0340

按 T_{80} 点排名，典型长寿命候选为 3_6C-80PER_3_6C、4_8C_80PER_4_8C（新）与 5C_67PER_4C（新）。其中新结构 4_8C 进入 Top 3 的 bootstrap 概率为 93.0%，证据最稳定；3_6C 与 5C_67PER_4C 分别为 75.75% 与 68.85%，排名保留不确定性。典型短寿命候选为 80PER_3_6C、4_8C_80PER_4_8C 与 3_7C_31PER_5_9C（新），其中旧结构 4_8C 与 3_7C 进入 Bottom 3 的概率均为 100%，短寿命特征稳定；80PER_3_6C 仅 60.35%，不宜作同等强度结论。

6.4 两两比较与寿命终点边界

精确置换检验配合 Holm 校正后，36 组电池级 T80 两两比较中没有确证显著的策略对；但另有 20 组未校正 bootstrap 区间不跨零。论文并列报告两者，既不把前者解释为九种策略完全等效，也不把后者当作多重比较后的确证差异——每策略仅 3-8 块电池时两两检验功效有限。

6.5 寿命外推的模型族敏感性

49 块电池均未观测到 80% SOH 终点，寿命需外推。本文比较局部线性、幂律与加速指数三族寿命外推模型，按 $L = 150$ 近端验证选择局部线性族（策略等权 RMSE 0.000706，优于幂律 0.000831 与指数 0.000849）。但三族模型给出的策略 T80 中位数跨度达 1.31-3.59 倍（如 3.6C 策略为 2377-8538 循环），且电池级 T80 的外推倍数高达 6-72 倍观测窗口。因此主 bootstrap 区间条件于线性族，三族包络单列为非置信区间的模型形式敏感性； L_{80}/T_{80} 只作外推代理，不作为观测寿命标签。




图 5 三族寿命外推模型的 T_{80} 对比（局部线性为主，幂律/指数为模型形式敏感性）

6.6 长寿命与短寿命策略的差异解释

典型长寿命候选的共同特征仍是限制中高 SOC 区间的充电倍率：5C_67PER_4C 在 67% SOC 后降至 4C，3_6C 在主要快充区间保持较温和的 3.6C；4_8C_80PER_4_8C（新）与旧结构 4_8C 名义参数相同，寿命却明显更优（ T_{80} 中位数 7362.2 对 1595.1 循环），说明结构/批次信息不能被 C_1, Q_1, C_2 完全替代。典型短寿命策略中，3_7C_31PER_5_9C 在 31% SOC 即切换至 5.9C，使电池在 31%–80% SOC 的较宽区间承受高倍率，其充电时间仅 10.85 min 却对应最低的 T_{80} 中位数（1000.8 循环）；旧结构 4_8C 则在主要快充区间持续 4.8C。持续的中高 SOC 高倍率可能增强电化学反应与欧姆发热，增加活性锂损失、界面副反应与析锂风险^[4]。

结果仍不支持“充电越慢，寿命一定越长”的单调关系：5C_67PER_4C 平均充电约 10.16 min，其 T_{80} 中位数（6434.0 循环）却高于充电约 14.28 min 的 80PER_3_6C（4672.7 循环）。更合理的解释是中高 SOC 倍率暴露、结构/批次与个体退化差异共同影响寿命，这也和“相同平均倍率下不同协议寿命不同”的文献观察对得上^[11]。窗口敏感性分析显示旧结构 4_8C 与 3_7C 始终位于末端，而中上游策略的 T_{80} 数值和局部次序会随末段窗口变化，因此最可靠的说法是长/短寿命组，而不是组内精确名次。这些解释基于数据关联和电化学文献，不是独立随机实验下的因果结论。

七、问题二模型的建立与求解

7.1 低维应力坐标

设 $q = Q_1/100$ ，两阶段倍率函数为

$$c(s) = \begin{cases} C_1, & 0 \leq s \leq q, \\ C_2, & q < s \leq 0.8, \end{cases} \quad (3)$$

据此定义理想恒流充电时间、总电流应力与高 SOC 加权应力：

$$T_0 = 60 \left(\frac{q}{C_1} + \frac{0.8 - q}{C_2} \right), \quad J = qC_1 + (0.8 - q)C_2, \quad H = \frac{1}{2} [C_1 q^2 + C_2 (0.8^2 - q^2)]. \quad (4)$$

J 描述主要充电区间的总体倍率暴露， H 对高 SOC 区间赋予更高权重。二者相关系数为 0.87， T_0 与 J 相关系数为 -0.984，三者不能同时进入正式模型。此外定义”高于阈值 s_0 的 SOC 区间应力”

$$J_{\text{high},s_0} = C_1 \max(q - s_0, 0) + C_2 (0.8 - \max(q, s_0)), \quad s_0 \in \{0.5, 0.6, 0.7\}, \quad (5)$$

用于隔离中高 SOC 高倍率暴露对退化的作用。参数设计审计显示：7 个参数完整的非基准策略的理想恒流时间 T_0 均约 9.99 ~ 10.01 min（仅 3_6C 基准为 13.33 min），即实验设计基本固定了名义恒流时间；而实测充电时间与 T_0 的差值达 0.14 ~ 3.08 min，反映恒压尾段与结构/批次的影响，不能只由 C_1, Q_1, C_2 精确决定。

7.2 约束退化混合模型

以第 151–200 循环的末段退化率（对数尺度）为响应，建立

$$y_{it} = a_i - r_i x_t - k x_t^2 + \varepsilon_{it}, \quad x_t = t/200, \quad (6)$$

$$\log r_i = \beta_0 + \beta_J \tilde{J}_{p(i)} + \beta_H \tilde{H}_{p(i)} + \beta_S S_{p(i)} + u_i \quad (7)$$

其中 $r_i > 0$ 、 $k \geq 0$ 保证平均 SOH 单调下降， u_i 为同策略电池差异， S 为”新结构/数据批次”联合标签（不作纯结构因果解释）。模型选择使用留一策略验证、AICc 与系数稳定性。

7.3 显著性检验的诊断属性

对策略间末段退化率做全局置换检验，得到 $F = 12.50$ 、尾部比例 5×10^{-5} （20000 次置换）。这个比例还不能直接当成严格的 p 值——协议组是固定的，各策略样本量

和方差又不齐，”全电池标签可交换”的前提本来就站不住，它更适合作为诊断性证据。在单暴露模型中，高 SOC 分位应力（ $J_{\text{high},50/60/70}$ ）均与退化方向一致，其中选定模型 $J_{\text{high},70}$ （SOC 高于 70% 区间的倍率暴露）的标准化系数为 0.0039（对相对损失为正、对 SOH200 为负），单暴露未校正尾部比例为 0.019；但经四个暴露量的选择校正后尾部比例为 0.065，且删除极端策略后常数模型胜出。2000 次整块电池 bootstrap 进一步显示， J_{high} 系数 100% 为正（方向稳健），而 H 相对常数基线的拟合改善为负，支持”高 SOC 区间应力而非总体应力是更一致的退化解释量”这一判断。 J_{high} 与退化的关联方向稳健，但不能据此宣称 SOC 阈值或参数的独立因果效应。以局部线性 T80 为响应的寿命口径主分析给出同样信号： J 单暴露模型较常数模型改善 20.29%，2000 次全流水线 bootstrap 入选频率 77.55%，但改善区间 $[-10.29\%, 47.86\%]$ 跨零；幂律与加速指数族冻结 T80 的点敏感性亦选择 J 且斜率一致为负，但没有跨族联合置信区间。短窗口退化与寿命外推两个口径的结论一致——方向稳健、证据强度不足。




图 6 各策略末段（151–200 循环）退化率




图 7 模型系数稳定性与选择校正

7.4 结构与批次混杂

两个具有相同 (4.8, 0.8, 4.8) 参数的策略分属旧/新结构，末段退化率存在差异；但结构、数据批次与策略参数完全混杂，无法将此差异干净地归因于”结构”。

7.5 小问结论

五个小问可以一并回答。策略间末段退化存在全局差异（诊断性尾部比例 5×10^{-5} ）； C_1, Q_1, C_2 与退化的关联方向一致——高 SOC 高倍率加剧退化——但受稀疏混杂设计限制，识别不出三个参数的独立因果效应；不同 SOC 区间高倍率的差异化作用方向与机理预期一致，高 SOC 分位应力 J_{high} 是比总体应力更一致的退化解释量，证据强度仍不足以形成因果断言。机制上，高 SOC 下高倍率促进锂析出与极化加剧，局限在于设计混杂与样本量不足^[4]。

八、问题三模型的建立与求解

8.1 特征提取

从每块电池前 L 循环的观测提取三类特征（表 5）：轨迹形态上的采样 SOH 点位、全区间线性斜率、多窗口局部斜率、近期曲率（近期斜率与前期斜率之差）、线性拟合残差标准差与近期变化范围；运行状态上的内阻、平均温度、充电时间的均值、近期均值与斜率；以及策略参数 C_1, q, C_2 、 C_1 缺失标记与 $J, H, J_{\text{high},50/60/70}$ 应力坐标。特征在每折内部用训练电池的中位数填充缺失、标准化。

表 5 问题三特征集

类别	特征
轨迹形态	采样 SOH 点位、全区间斜率、多窗口局部斜率、曲率、残差标准差、近期范围
运行状态	内阻、平均温度、充电时间的均值、近期均值与斜率（共 9 维）
策略参数	C_1, q, C_2, C_1 缺失标记、 $J, H, J_{\text{high},50/60/70}$

8.2 候选模型与部署选择

比较六类候选模型，主模型 $P1_linear$ （线性外推）用前 L 循环拟合线性趋势并外推未来 SOH。因部署时固定提供 150 个观测循环，按 $L = 150$ 外层留一电池冻结 $P1_linear$ ：其在 $L = 150$ 的策略等权 LOBO RMSE 为 0.000617（表 6），是唯一进入并列容差并被选为部署模型的候选。轨迹岭模型 C_ridge 在多长度综合指标上排名第一，但该指标是将不同 L 的误差加权合成，与最终固定 $L = 150$ 的部署场景不同，故保留为多长度综合稳健性敏感性而非部署模型。六模型排名见表 6。 $L = 150$ 下仅 C_ridge 与 $D_ensemble$ 相对 $P1_linear$ 的成对 bootstrap 区间跨零、名次不稳定。另以 40 折 $L = 150$ 专用嵌套选模评估完整”先选族再部署”流程，策略等权 RMSE 为 0.000704，与固定候选口径 0.000617 分开报告，不把固定赢家点误差当成完整选模流程的无偏误差。

表 6 六类候选模型排名： $L = 150$ 序与多长度综合序

$L = 150$ 排名	模型	$L = 150$ 策略等权 RMSE	多长度综合排名	部署/角色	选定
1	$P1_linear$ （线性外推）	0.000617	3	部署	是
2	C_ridge （轨迹岭回归）	0.000669	1	多长度稳健敏感性	否
3	$D_ensemble$ （集成）	0.000701	2	候选	否
4	$B_strategy$ （策略迁移）	0.000785	4	候选	否
5	A_power （幂律）	0.000893	5	候选	否
6	$P0_persistence$ （持久化）	0.002400	6	候选	否




图 8 六候选模型随早期数据长度的 LOBO RMSE

$L = 150$ 特征消融显示（表 7）：仅用动态轨迹特征的 RMSE 0.000650 略优于完整模型，说明策略参数特征在该窗口不提供增量精度。预测区间由冻结模型族在 40 块训练电池上的外层交叉拟合绝对残差校准，以 95% 目标边际覆盖率取第 39/40 顺序统计量，为偏保守的逐循环点区间；同一残差也参与选族，可能受赢家偏差影响，不构成独立测试覆盖率。

表 7 $L = 150$ 特征消融（策略等权 RMSE）

特征组合	RMSE
仅动态轨迹特征	0.000650
动态 + 策略参数	0.000686
完整（含策略标签）	0.000669

8.3 测试电池预测

9 块测试电池的 $P1_{linear}$ 预测 SOH200 与保守点区间见表 8。区间为逐循环点区间，不构成整条轨迹联合区间或独立测试覆盖率。

表 8 9 块测试电池预测 ($P1_{linear}$)

电池	策略	预测 SOH200	保守点区间	情景 T_{80}
2	3_6C-80PER_3_6C	0.994184	[0.992014, 0.996353]	1249.4
5	80PER_3_6C	0.993911	[0.991742, 0.996081]	895.5
9	4_8C_80PER_4_8C	0.982823	[0.980654, 0.984993]	706.0
10	5C_67PER_4C (新)	0.996097	[0.993927, 0.998266]	1921.7
11	5_3C_54PER_4C (新)	0.995557	[0.993387, 0.997726]	2911.7
14	5_6C_19PER_4_6C (新)	0.996338	[0.994169, 0.998508]	1674.8
16	3_7C_31PER_5_9C (新)	0.961868	[0.959699, 0.964038]	912.4
24	5_6C_36PER_4_3C (新)	0.996097	[0.993928, 0.998266]	989.3
25	4_8C_80PER_4_8C (新)	0.996390	[0.994221, 0.998560]	2746.8




图 9 9 块测试电池 151-200 循环预测（实线单调投影、阴影保守点区间）

8.4 80% 寿命外推的边界

80% 寿命终点 (T_{80}) 对拟合起点与 raw/projected 口径高度敏感 (图 10)，有限情景值范围为 **706.0–4899.3** 循环。这里的拼接幂律情景是”真实 1–150 循环与线性预测 151–200 循环拼接后另行拟合幂律曲线”得到的，不能解释为部署线性模型自身的寿命终点 (后者单独列为 native 线性外推状态，部分电池超过 5000 循环)。49 块电池都没有观测到 80% SOH， T_{80} 只能作为模型情景交点，谈不上实证寿命精度，论文把它和短期 LOBO 误差分开陈述。




图 10 T_{80} 情景外推敏感性 (红菱形为默认情景)

九、问题四模型的建立与求解

9.1 离散 Pareto 主模型 (M0)

对策略 p 定义充电时间与退化量

$$T_p = \text{mean}_{i \in p}(\text{chargetime}_i), \quad D_p = \text{mean}_{i \in p} \left(1 - \text{SOH}_{i,200}/b_i \right), \quad (8)$$

其中 b_i 为电池基线容量。若不存在策略 r 使 $T_r \leq T_p$ 且 $D_r \leq D_p$ (至少一项严格)，则 p 位于 Pareto 前沿。时间与退化用整块电池 bootstrap 量化不确定性。理论恒流时间 T_0 仅作解释量，实测时间含恒压尾段与结构/批次影响。

9.2 Pareto 前沿与推荐

点估计 Pareto 前沿含 3_6C 基准、4_8C 新结构与 5_3C_54PER_4C (表 9)，bootstrap 显示前沿成员不稳定。5_3C_54PER_4C 在点估计上同时更快且退化更低，是点 Pareto

快速推荐：5C_67PER_4C 严格被支配，但二者时间差与退化差的整块电池 bootstrap 区间均跨零（退化差区间 $[-0.0015, +0.0012]$ ），且 5_3C 退化更低的概率不足 0.95，因此它保留为非前沿近似并列敏感性项，而不是共同主推荐。

表 9 点估计 Pareto 前沿（40 块完整电池）

策略	n	时间/min	200 循环退化	末段衰减率	Pareto 频率
3_6C-80PER_3_6C	2	13.388	0.000520	0.0000500	0.746
4_8C_80PER_4_8C（新）	5	11.160	0.001622	0.0000276	0.518
5_3C_54PER_4C	7	10.158	0.001800	0.0000315	0.890




图 11 充电时间-退化 Pareto 前沿与 bootstrap 不确定性

表 10 推荐策略与典型策略对比

策略	时间/min	200 循环退化	较长寿命时间差	较长寿命退化差
3_6C-80PER_3_6C（典型长寿命）	13.388	0.000520	0	0
5_3C_54PER_4C（推荐）	10.158	0.001800	-3.230	+0.001280
5C_67PER_4C（近似并列敏感）	10.159	0.001993	-3.229	+0.001472
3_7C_31PER_5_9C（典型短寿命）	10.852	0.033684	-2.536	+0.033164

推荐 5_3C_54PER_4C ($C_1 = 5.3, Q_1 = 54\%, C_2 = 4.0$): 若应用要求优先缩短时间并接受约 0.13% 的 200 循环相对退化，该策略是点 Pareto 快速推荐。相对典型长寿命基准缩短约 24% 时间、退化仅增约 0.13 个百分点；相对典型短寿命策略更快且退化低约 0.032。其机理是低 SOC 段使用较高倍率、较早切换至 4C，形成观测数据支持的时间-退化折中。注意 5_3C_54PER_4C 与 5C_67PER_4C 时间差不足 0.01 min，二者近

似并列；其余两个新结构策略（5_6C_36PER_4_3C、5_6C_19PER_4_6C）与最快组相差约 0.06–0.09 min，不并入最快组，不能宣称 5_3C 显著更快。

末段斜率口径揭示一处反转：3_6C 基准的 200 循环累计退化点估计最低（0.000520），但其末段（151–200）每循环衰减率 0.0000500 反而高于 4_8C 新结构（0.0000277）与 5_3C（0.0000315），因此在末段斜率前沿上被二者支配。只有 4_8C 新结构与 5_3C 在 **SOH200** 与末段斜率两个口径下都位于前沿；而 3_6C 的累计退化均值仅来自 $n = 2$ 样本且策略内标准差高于均值本身，不宜对“最低退化”作过强断言。

9.3 条件约束决策与连续响应面淘汰

除单点推荐外，本文还给出“给定退化容忍度 $D_{\max}$ 下选择最短时间”的条件决策：当 $D_{\max} = 0.0005$ 时以 74% 概率无可行策略、3_6C 基准被选频率 24.4%；当 $D_{\max} = 0.0017$ 时 5_3C 被选频率 42.4%、4_8C 新结构 28.9%。这些容忍度仅为展示决策规则的示例场景，不是工程安全标准。权重扫描（min-max 标准化）仅作**偏好敏感性诊断**：使用全部 9 个观测策略（含被支配点）归一化时 $\lambda = 0.1$ 即选择 5.3C；而仅用 Pareto 点归一化时，要到 $\lambda = 0.6$ 才从 3.6C 切换到 5.3C。该差异说明权重结论依赖标准化集合，不能把任一加权表当成无条件主推荐，正式决策以 Pareto 前沿、退化约束与 bootstrap 稳定性为准。

受限连续响应面（单 J 岭模型）在 oracle 坐标压力测试中平均 RMSE 为 0.015740，7 折中 6 折未优于常数基线。进一步审计显示，最差的 3.6C 留一折位于训练 J 范围之外，产生负退化预测并贡献总平方误差的 72.2%；剔除该折后 M1 平均 RMSE 仍为 0.009652，略差于常数基线 0.009324，故失败方向不依赖该折。据此连续三参数优化被正式淘汰，正式答案退回离散 Pareto；但这只否定当前单 J 岭代理，不证明所有连续代理或后续新增实验均无效。

9.4 合理性、适用范围与外推风险

推荐合理性来自：位于点估计 Pareto 前沿、bootstrap Pareto 频率最高（0.890）、两种时间口径下前沿不变、SOH200 与末段斜率结论方向一致。以寿命 T80 为响应时，4_8C 新结构、5C_67PER_4C 与 5_3C_54PER_4C 在三种 **T80** 模型族下都位于 **Pareto** 前沿（跨族稳健），而 3_6C 基准仅在局部线性族前沿，进一步支持推荐策略的稳健性。结论严格限定在 9 个已观测策略范围内，不宣称 C_1, Q_1, C_2 的独立因果最优值，不外推到未观测倍率、SOC 区间或新电芯结构^[4,5]。

十、模型检验与灵敏度分析

10.1 残差与假设诊断

问题一主模型训练残差的一阶自相关约为 0.645，说明平滑后仍存在循环内序列相关，故不确定性统一用整块电池 bootstrap 处理，而非假定残差独立；残差的均值与幅度在策略间无明显系统偏差。问题三部署模型的逐循环外层交叉拟合残差均值接近零，预测区间由该残差的经验分位校准。

10.2 方法与口径对比检验

问题二在局部线性、幂律与加速指数三族 T80 口径下均选择 J 且斜率一致为负，说明高 SOC 应力与寿命的关联方向跨模型族稳健；问题三六类候选模型在 $L = 150$ 的排名、嵌套选模流程与部署选择交叉一致，固定候选口径 (0.000617) 与完整选模流程口径 (0.000704) 分开报告；问题四在 SOH200、末段斜率与寿命 T80 三个响应口径下，4_8C 新结构与 5_3C_54PER_4C 均位于 Pareto 前沿，结论跨口径稳健。

10.3 清洗规则敏感性

固定 3 处修复但改变局部趋势窗口 (7/11/15 点) 后，策略排序不变；保留异常原始值仅影响个别策略指标。

10.4 响应口径敏感性

Q1 以电池级 T_{80} 为寿命主口径，SOH200 与前 200 循环损失仅作辅助交叉检验；短寿命分组跨口径方向一致 (旧结构 4_8C 与 3_7C 均居末端)，长寿命组内精确名次随口径变化，寿命结论以 T_{80} 为准；Q4 的退化代理允许为负 (受基线噪声影响)，如 3.6C 策略退化均值为 0.000520、bootstrap 区间下界为负，已接近测量噪声地板，故不对“最低退化”作过强断言。

10.5 时间口径敏感性

Q4 采用 40 块完整电池逐循环充电时间均值为主口径，官方汇总口径作敏感性审计；两口径在部分策略差异明显 (如旧结构 4.8C 为 10.45 与 13.08 min)，但 Pareto 前沿与推荐策略不变。

10.6 模型选择敏感性

Q3 部署模型对选择标准敏感： $L = 150$ 单点最优为 $P1_linear$ ，多长度综合最优为 C_ridge ，论文明确区分部署模型与稳健性敏感性，避免把综合指标误当部署依据。

十一、模型评价与推广

11.1 模型优点

- 数据清洗最小干预、全程审计留痕，修复决策与人工核对一致；
- 始终以整块电池为推断单位，正确处理重复测量与聚类重采样；
- 多模型互证，并用置换检验、选择校正、bootstrap 量化不确定性，且明确区分诊断性结论与确证性结论；
- 报告了设计混杂导致的因果识别边界，不强行宣称参数独立效应。

11.2 模型不足

- 9 种策略的稀疏混杂设计使 C_1, Q_1, C_2 独立因果效应不可识别；
- 无真实 80% SOH 终点，寿命终点均为外推；
- 2 电池策略（如 3.6C）的分布组合极少，bootstrap 只能作粗粒度证据。

11.3 推广方向

可引入层次贝叶斯模型刻画策略总体与电池个体差异并部分汇聚^[3,9]，在闭环优化框架中结合贝叶斯优化与不确定性进行实验设计^[2]，并针对末段斜率反映的退化反转做更细致的机理分析^[5]。

AI 工具使用声明

本参赛队在竞赛过程中使用了 AI 工具，主要用于【代码调试、语言润色、数据处理与建模方案讨论】，详细使用情况见支撑材料。

参考文献

- [1] Severson K A, Attia P M, Jin N, et al. Data-driven prediction of battery cycle life before capacity degradation[J]. Nature Energy, 2019, 4(5): 383-391.
- [2] Attia P M, Grover A, Jin N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning[J]. Nature, 2020, 578(7795): 397-402.
- [3] Jiang B, Gent W E, Mohr F, et al. Bayesian learning for rapid prediction of lithium-ion battery-cycling protocols[J]. Joule, 2021, 5(12): 3187-3203.
- [4] Keil P, Jossen A. Charging protocols for lithium-ion batteries and their impact on cycle life[J]. Journal of Energy Storage, 2016, 6: 125-141.

- [5] Schuster S F, Bach T C, Fleder E, et al. Nonlinear aging characteristics of lithium-ion cells under different operational conditions[J]. Journal of Energy Storage, 2015, 1: 44-53.
- [6] Saxena S, Xing Y, Kwon D, et al. Accelerated degradation model for C-rate loading of lithium-ion batteries[J]. International Journal of Electrical Power & Energy Systems, 2019, 107: 438-445.
- [7] Richardson R R, Osborne M A, Howey D A. Gaussian process regression for forecasting battery state of health[J]. Journal of Power Sources, 2017, 357: 209-219.
- [8] Liu K, Hu X, Wei Z, et al. Modified Gaussian process regression models for cyclic capacity prediction of lithium-ion batteries[J]. IEEE Transactions on Transportation Electrification, 2019, 5(4): 1225-1236.
- [9] Zhou Z, Howey D A. Bayesian hierarchical modelling for battery lifetime early prediction[J]. IFAC-PapersOnLine, 2023, 56(2): 6117-6123.
- [10] Geslin A, van Vlijmen B, Cui X, et al. Selecting the appropriate features in battery lifetime predictions[J]. Joule, 2023, 7(9): 1956-1965.
- [11] Zhang S S. The effect of the charging protocol on the cycle life of a Li-ion battery[J]. Journal of Power Sources, 2006, 161(2): 1385-1391.

附录 A 支撑材料文件列表

表 11 支撑材料文件列表

类别	路径	说明
数据	data/processed/q1_cleaned/*.csv	清洗后摘要表与循环表
结果	result/q1/paper/*.csv	问题一结果与结论
结果	result/q2/03_formal_validation/	问题二正式验证
结果	result/q3/03_final_predictions/	问题三最终预测
结果	result/q4/02_full_validation/	问题四全量验证与推荐
代码	src/q1_models/ 等	各问模型核心源码
代码	scripts/q1-q4/	各问实验入口脚本

附录 B 核心算法代码

以下为核心模型源码（完整可运行代码见支撑材料，运行顺序见各 scripts 入口）。

```

1 """Numerical core for the three comparable Question 1 curve models."""
2
3 from __future__ import annotations
4
5 from dataclasses import dataclass
6 from typing import Iterable
7
8 import numpy as np
9 import pandas as pd
10
11
12 MODEL_POLYNOMIAL = "polynomial_mixed"
13 MODEL_SPLINE = "spline_mixed"
14 MODEL_FUNCTIONAL = "functional_ridge"
15 MODEL_TYPES = (MODEL_POLYNOMIAL, MODEL_SPLINE, MODEL_FUNCTIONAL)
16
17
18 @dataclass(frozen=True)
19 class ModelConfig:
20     lambda_random: float = 0.1
21     lambda_curve: float = 0.01
22
23
24 @dataclass
25 class PopulationCurveModel:
26     model_type: str
27     config: ModelConfig
28     policy_names: tuple[str, ...]
29     fixed_coef: np.ndarray
30     battery_ids: np.ndarray
31     random_coef: np.ndarray | None = None
32     cell_coef: np.ndarray | None = None
33     cell_policy: np.ndarray | None = None
34
35     def predict(self, policy: str | Iterable[str], cycle: Iterable[float]) -> np.ndarray:
36         cycles = np.asarray(cycle, dtype=float).reshape(-1)
37         policies = np.asarray([policy] * len(cycles) if isinstance(policy, str) else policy, dtype=str)
38         if len(policies) != len(cycles):
39             raise ValueError("policy and cycle must have the same length")
40         basis = make_basis(self.model_type, cycles)
41         output = np.full(len(cycles), np.nan, dtype=float)
42         policy_to_index = {name: i for i, name in enumerate(self.policy_names)}
43         for name in np.unique(policies):
44             if name not in policy_to_index:
45                 raise KeyError(f"policy absent from training data: {name}")
46             use = policies == name
47             output[use] = basis[use] @ self.fixed_coef[policy_to_index[name]]
48         return output
49
50
51 def make_basis(model_type: str, cycle: Iterable[float]) -> np.ndarray:
52     """Return the explicitly specified cycle basis, using  $x=t/200$ ."""
53     x = np.asarray(cycle, dtype=float).reshape(-1) / 200.0
54     if model_type == MODEL_POLYNOMIAL:
55         return np.column_stack((np.ones_like(x), x, x**2))
56     if model_type in (MODEL_SPLINE, MODEL_FUNCTIONAL):
57         columns = [np.ones_like(x), x, x**2, x**3]
58         columns.extend(np.maximum(x - knot, 0.0) ** 3 for knot in (0.25, 0.50, 0.75))
59         return np.column_stack(columns)
60     raise ValueError(f"unknown model type: {model_type}")
61
62
63 def candidate_configs(model_type: str) -> list[ModelConfig]:
64     if model_type == MODEL_POLYNOMIAL:
65         return [ModelConfig(value, 0.0) for value in (0.01, 0.1, 1.0, 10.0)]
66     if model_type == MODEL_SPLINE:
67         return [
68             ModelConfig(random_penalty, curve_penalty)
69             for random_penalty in (0.03, 0.3, 3.0)
70             for curve_penalty in (0.001, 0.01, 0.1, 1.0)
71         ]
72     if model_type == MODEL_FUNCTIONAL:
73         return [ModelConfig(0.0, value) for value in (0.0001, 0.001, 0.01, 0.1, 1.0)]
74     raise ValueError(f"unknown model type: {model_type}")
75
76
77 def fit_population_model(data: pd.DataFrame, model_type: str, config: ModelConfig) -> PopulationCurveModel:
78     """Fit a strategy population curve with equal inferential units at battery level.
79
80     The two mixed candidates minimize
81     
$$||y - F\beta - Zb||^2 + \lambda_{\text{curve}} ||P\beta||^2 + \lambda_{\text{random}} ||b||^2,$$

82     where Z contains a random intercept and slope for each battery. The
83     functional candidate first smooths each battery, then averages cell
84     coefficients within strategy so batteries receive equal weight.
85     """
86     required = {"battery_id", "cycle", "policy", "SOH_clean"}
87     missing = required.difference(data.columns)
88     if missing:
89         raise ValueError(f"missing columns: {sorted(missing)}")
90     frame = data.loc[np.isfinite(data["SOH_clean"]) & np.isfinite(data["cycle"])].copy()
91     frame["policy"] = frame["policy"].astype(str)
92     policy_names = tuple(pd.unique(frame["policy"]).tolist())
93     battery_ids = pd.unique(frame["battery_id"]).astype(int)
94     policy_index = {name: i for i, name in enumerate(policy_names)}
95     battery_index = {int(value): i for i, value in enumerate(battery_ids)}
96     basis = make_basis(model_type, frame["cycle"].to_numpy())
97     n_rows, n_basis = basis.shape

```

```

99
100 if model_type in (MODEL_POLYNOMIAL, MODEL_SPLINE):
101     fixed = np.zeros((n_rows, len(policy_names) * n_basis), dtype=float)
102     pidx = frame["policy"].map(policy_index).to_numpy(dtype=int)
103     rows = np.arange(n_rows)
104     for j in range(n_basis):
105         fixed[rows, pidx * n_basis + j] = basis[:, j]
106
107     random = np.zeros((n_rows, 2 * len(battery_ids)), dtype=float)
108     bidx = frame["battery_id"].map(battery_index).to_numpy(dtype=int)
109     x = frame["cycle"].to_numpy(dtype=float) / 200.0
110     random[rows, 2 * bidx] = 1.0
111     random[rows, 2 * bidx + 1] = x
112     design = np.column_stack((fixed, random))
113
114     penalty = np.zeros(design.shape[1], dtype=float)
115     if model_type == MODEL_SPLINE:
116         for p in range(len(policy_names)):
117             start = p * n_basis
118             penalty[start + 2 : start + n_basis] = config.lambda_curve
119             penalty[len(policy_names) * n_basis :] = config.lambda_random
120             coefficient = _penalized_solve(design, frame["SOH_clean"].to_numpy(), penalty)
121             fixed_coef = coefficient[: len(policy_names) * n_basis].reshape(len(policy_names), n_basis)
122             random_coef = coefficient[len(policy_names) * n_basis :].reshape(len(battery_ids), 2)
123             return PopulationCurveModel(
124                 model_type, config, policy_names, fixed_coef, battery_ids, random_coef=random_coef
125             )
126
127 if model_type == MODEL_FUNCTIONAL:
128     cell_coef = np.empty((len(battery_ids), n_basis), dtype=float)
129     cell_policy = np.empty(len(battery_ids), dtype=object)
130     penalty = np.zeros(n_basis, dtype=float)
131     penalty[2:] = config.lambda_curve
132     for i, battery_id in enumerate(battery_ids):
133         use = frame["battery_id"].to_numpy() == battery_id
134         cell_coef[i] = _penalized_solve(basis[use], frame.loc[use, "SOH_clean"].to_numpy(), penalty)
135         cell_policy[i] = frame.loc[use, "policy"].iloc[0]
136         fixed_coef = np.vstack([cell_coef[cell_policy == name].mean(axis=0) for name in policy_names])
137         return PopulationCurveModel(
138             model_type,
139             config,
140             policy_names,
141             fixed_coef,
142             battery_ids,
143             cell_coef=cell_coef,
144             cell_policy=cell_policy,
145         )
146     raise ValueError(f"unknown model type: {model_type}")
147
148
149 def _penalized_solve(design: np.ndarray, response: np.ndarray, penalty: np.ndarray) -> np.ndarray:
150     lhs = design.T @ design
151     scale = max(float(np.trace(lhs)) / max(lhs.shape[0], 1), 1.0)
152     lhs.flat[:: lhs.shape[0] + 1] += penalty + 1e-12 * scale
153     rhs = design.T @ response
154     try:
155         return np.linalg.solve(lhs, rhs)
156     except np.linalg.LinAlgError:
157         return np.linalg.lstsq(lhs, rhs, rcond=1e-12)[0]

```

```

1 """Shared numerical core for Question 2 smoke tests.
2
3 The strategy parameter coordinate, rather than a cycle row or a battery, is the
4 independent design unit. All parameter-response regressions therefore average
5 within strategy first and validate by leaving an entire parameter coordinate out.
6 """
7
8 from __future__ import annotations
9
10 from dataclasses import dataclass
11 from pathlib import Path
12
13 import numpy as np
14 import pandas as pd
15
16
17 SEED = 20260814
18 LAMBDA_GRID = (0.0, 0.01, 0.1, 1.0, 10.0, 100.0)
19 CHECKPOINTS = np.array([25, 50, 75, 100, 125, 150, 175, 200], dtype=int)
20
21
22 @dataclass(frozen=True)
23 class Candidate:
24     name: str
25     features: tuple[str, ...]
26     family: str = "ridge"
27     quadratic_cycle: bool = False
28
29
30 STRATEGY_CANDIDATES = (
31     Candidate("constant_mean", (), "constant"),
32     Candidate("nearest_coordinate", ("C1", "q", "C2"), "nearest"),
33     Candidate("ridge_raw_C1_q_C2", ("C1", "q", "C2")),
34     Candidate("ridge_stage_E1_E2", ("E1", "E2")),
35     Candidate("ridge_J", ("J",)),
36     Candidate("ridge_H", ("H",)),
37     Candidate("ridge_J_H", ("J", "H")),
38     Candidate("ridge_J_high50", ("J_high50",)),

```

```

39     Candidate("ridge_3high60", ("J_high_60",)),
40     Candidate("ridge_3high70", ("J_high_70",)),
41 )
42
43
44 HIERARCHICAL_CANDIDATES = (
45     Candidate("hier_cycle_no_stress", (), "hierarchical", False),
46     Candidate("hier_cycle_J_linear", ("J",), "hierarchical", False),
47     Candidate("hier_cycle_H_linear", ("H",), "hierarchical", False),
48     Candidate("hier_cycle_J_H_linear", ("J", "H"), "hierarchical", False),
49     Candidate("hier_cycle_J_quadratic", ("J",), "hierarchical", True),
50 )
51
52
53 def load_clean_data(project_root: Path) -> tuple[pd.DataFrame, pd.DataFrame]:
54     cycle_path = project_root / "data" / "processed" / "q1_cleaned" / "cycle_train_clean.csv"
55     summary_path = project_root / "data" / "processed" / "q1_cleaned" / "battery_summary_clean.csv"
56     cycles = pd.read_csv(cycle_path)
57     summary = pd.read_csv(summary_path)
58     counts = cycles.groupby("battery_id", observed=True)["cycle"].nunique()
59     complete_ids = counts[counts.eq(200)].index
60     cycles = cycles[cycles["battery_id"].isin(complete_ids)].copy()
61     summary = summary[summary["battery_id"].isin(complete_ids)].copy()
62     if cycles["SOH_clean"].isna().any():
63         raise ValueError("SOH_clean contains missing values in the complete cohort")
64     return cycles, summary
65
66
67 def coordinate_id(frame: pd.DataFrame) -> pd.Series:
68     return (
69         frame["C1"].map(lambda value: f"{value:.3f}")
70         + "|"
71         + frame["q"].map(lambda value: f"{value:.3f}")
72         + "|"
73         + frame["C2"].map(lambda value: f"{value:.3f}")
74     )
75
76
77 def add_protocol_features(frame: pd.DataFrame) -> pd.DataFrame:
78     result = frame.copy()
79     result["q"] = result["Q1"] / 100.0
80     result["structure_batch"] = result["policy"].astype(str).str.contains("NEWSTRUCTURE").astype(int)
81     result["T0"] = 60.0 * (result["q"] / result["C1"] + (0.8 - result["q"]) / result["C2"])
82     result["E1"] = result["q"] * result["C1"]
83     result["E2"] = (0.8 - result["q"]) * result["C2"]
84     result["J"] = result["E1"] + result["E2"]
85     result["H"] = 0.5 * (
86         result["C1"] * result["q"] ** 2
87         + result["C2"] * (0.8**2 - result["q"] ** 2)
88     )
89     for threshold in (0.5, 0.6, 0.7):
90         result[f"J_high_{int(threshold * 100)}"] = np.where(
91             threshold < result["q"],
92             result["C1"] * (result["q"] - threshold)
93             + result["C2"] * (0.8 - result["q"]),
94             result["C2"] * (0.8 - threshold),
95         )
96     result["coordinate_id"] = coordinate_id(result)
97     return result
98
99
100 def battery_degradation_summary(cycles: pd.DataFrame, battery_meta: pd.DataFrame) -> pd.DataFrame:
101     records: list[dict[str, float | int | str]] = []
102     meta = battery_meta.set_index("battery_id")
103     for battery_id, group in cycles.groupby("battery_id", observed=True):
104         group = group.sort_values("cycle")
105         baseline = float(group.loc[group["cycle"].between(1, 5), "SOH_clean"].mean())
106         end_soh = float(group.loc[group["cycle"].between(196, 200), "SOH_clean"].mean())
107         x = group["cycle"].to_numpy(dtype=float) / 200.0
108         degradation = 1.0 - group["SOH_clean"].to_numpy(dtype=float) / baseline
109         design = np.column_stack((np.ones_like(x), x, x**2))
110         coef = np.linalg.lstsq(design, degradation, rcond=None)[0]
111         row = meta.loc[battery_id]
112         records.append(
113             {
114                 "battery_id": int(battery_id),
115                 "policy": str(row["policy"]),
116                 "C1": float(row["C1"]) if np.isfinite(row["C1"]) else np.nan,
117                 "Q1": float(row["Q1"]),
118                 "C2": float(row["C2"]),
119                 "baseline_soh": baseline,
120                 "soh200": end_soh,
121                 "relative_loss200": 1.0 - end_soh / baseline,
122                 "curve_loss200": float(coef.sum()),
123                 "curve_linear": float(coef[1]),
124                 "curve_quadratic": float(coef[2]),
125                 "mean_chargetime": float(row["mean_chargetime"]),
126                 "mean_IR": float(row["mean_IR"]),
127                 "mean_Tavg": float(row["mean_Tavg"]),
128                 "flag_battery41": int(battery_id == 41),
129             }
130         )
131     return add_protocol_features(pd.DataFrame.from_records(records))
132
133
134 def strategy_summary(battery: pd.DataFrame) -> pd.DataFrame:
135     complete = battery[battery["C1"].notna()].copy()
136     feature_columns = [
137         "C1", "Q1", "C2", "q", "T0", "E1", "E2", "J", "H",

```

```

138     "J_high_50", "J_high_60", "J_high_70", "structure_batch",
139 ]
140 response_columns = [
141     "soh200", "relative_loss200", "curve_loss200", "curve_linear", "curve_quadratic",
142     "mean_chargetime", "mean_IR", "mean_Tavg",
143 ]
144 aggregations: dict[str, str | tuple[str, str]] = {column: "first" for column in feature_columns}
145 aggregations.update({column: "mean" for column in response_columns})
146 aggregations["n_batteries"] = ("battery_id", "size")
147 result = complete.groupby("policy", as_index=False, observed=True).agg(**{
148     key: value if isinstance(value, tuple) else (key, value) for key, value in aggregations.items()
149 })
150 result["coordinate_id"] = coordinate_id(result)
151 result["equal_time_cohort"] = result["policy"].ne("3_6C-80PER_3_6C").astype(int)
152 result["explicit_new_structure_cohort"] = result["structure_batch"].eq(1).astype(int)
153 return result.sort_values("policy").reset_index(drop=True)
154
155
156 def standardized(train: pd.DataFrame, test: pd.DataFrame, features: tuple[str, ...]) -> tuple[np.ndarray, np.ndarray, np.ndarray, np.
157     ndarray]:
158     if not features:
159         return np.empty((len(train), 0)), np.empty((len(test), 0)), np.array([], np.array([]))
160     mean = train.loc[:, features].mean(axis=0).to_numpy(dtype=float, copy=True)
161     scale = train.loc[:, features].std(axis=0, ddof=0).to_numpy(dtype=float, copy=True)
162     scale[scale < 1e-12] = 1.0
163     return (
164         (train.loc[:, features].to_numpy(dtype=float) - mean) / scale,
165         (test.loc[:, features].to_numpy(dtype=float) - mean) / scale,
166         mean,
167         scale,
168     )
169
170 def ridge_fit(x: np.ndarray, y: np.ndarray, ridge_lambda: float) -> np.ndarray:
171     design = np.column_stack((np.ones(len(x)), x))
172     penalty = np.eye(design.shape[1]) * ridge_lambda
173     penalty[0, 0] = 0.0
174     lhs = design.T @ design + penalty
175     return np.linalg.lstsq(lhs, design.T @ y, rcond=None)[0]
176
177
178 def ridge_predict(coef: np.ndarray, x: np.ndarray) -> np.ndarray:
179     return np.column_stack((np.ones(len(x)), x)) @ coef
180
181
182 def select_lambda_inner(train: pd.DataFrame, response: str, features: tuple[str, ...]) -> float:
183     groups = train["coordinate_id"].unique().tolist()
184     if len(groups) <= 3:
185         return 10.0
186     scores: list[tuple[float, float]] = []
187     for ridge_lambda in LAMBDA_GRID:
188         errors: list[float] = []
189         for group in groups:
190             inner_train = train[train["coordinate_id"].ne(group)]
191             inner_test = train[train["coordinate_id"].eq(group)]
192             x_train, x_test, _, _ = standardized(inner_train, inner_test, features)
193             coef = ridge_fit(x_train, inner_train[response].to_numpy(dtype=float), ridge_lambda)
194             prediction = ridge_predict(coef, x_test)
195             errors.append(float(np.mean((prediction - inner_test[response].to_numpy(dtype=float)) ** 2)))
196         scores.append((float(np.mean(errors)), ridge_lambda))
197     minimum = min(value for value, _ in scores)
198     tolerance = minimum * 1.01 + 1e-15
199     return max(ridge_lambda for value, ridge_lambda in scores if value <= tolerance)
200
201
202 def nearest_prediction(train: pd.DataFrame, test: pd.DataFrame, response: str) -> np.ndarray:
203     features = ("C1", "q", "C2")
204     x_train, x_test, _, _ = standardized(train, test, features)
205     y = train[response].to_numpy(dtype=float)
206     output = np.empty(len(test), dtype=float)
207     for index, row in enumerate(x_test):
208         distance = np.sum((x_train - row) ** 2, axis=1)
209         output[index] = y[int(np.argmin(distance))]
210     return output
211
212
213 def fit_hierarchical_penalized(
214     train_cycles: pd.DataFrame,
215     train_strategy: pd.DataFrame,
216     features: tuple[str, ...],
217     quadratic: bool,
218     lambda_fixed: float = 1.0,
219     lambda_battery: float = 1.0,
220     lambda_policy: float = 10.0,
221 ) -> tuple[np.ndarray, dict[str, object]]:
222     """Fit a linearized smoke surrogate of Model C by penalized least squares.
223
224     
$$y_i = \beta_0 + \beta_1 x_i + \sum_k \beta_k z_{pk} x_i + \beta_q q_i^2 + a_i + u_i x_i + v_i x_i + \text{error}_i$$

225
226     For runtime, this smoke fit uses cycle 1 and every fifth cycle. The formal
227     nonlinear exponential-link/AR(1) likelihood is intentionally not claimed
228     here. This surrogate answers whether the additional hierarchy has enough
229     predictive signal to justify a later full Model C fit.
230     """
231     strategy_lookup = train_strategy.set_index("policy")
232     frame = train_cycles[
233         train_cycles["policy"].isin(strategy_lookup.index)
234         & (train_cycles["cycle"].eq(1) | train_cycles["cycle"].mod(5).eq(0))
235     ]

```

```

236 ].copy()
237 policies = sorted(frame["policy"].unique().tolist())
238 batteries = sorted(frame["battery_id"].unique().tolist())
239 p_index = {name: index for index, name in enumerate(policies)}
240 b_index = {value: index for index, value in enumerate(batteries)}
241 means = train_strategy.loc[:, features].mean(axis=0).to_numpy(dtype=float, copy=True) if features else np.array([])
242 scales = train_strategy.loc[:, features].std(axis=0, ddof=0).to_numpy(dtype=float, copy=True) if features else np.array([])
243 if len(scales):
244     scales[scales < 1e-12] = 1.0
245 x = frame["cycle"].to_numpy(dtype=float) / 200.0
246 fixed_columns = [np.ones(len(frame)), x]
247 for feature, mean, scale in zip(features, means, scales):
248     z = frame["policy"].map(strategy_lookup[feature]).to_numpy(dtype=float)
249     fixed_columns.append(((z - mean) / scale) * x)
250 if quadratic:
251     fixed_columns.append(x**2)
252 fixed = np.column_stack(fixed_columns)
253 random_battery = np.zeros((len(frame), 2 * len(batteries)))
254 random_policy = np.zeros((len(frame), len(policies)))
255 rows = np.arange(len(frame))
256 bidx = frame["battery_id"].map(b_index).to_numpy(dtype=int)
257 pidx = frame["policy"].map(p_index).to_numpy(dtype=int)
258 random_battery[rows, 2 * bidx] = 1.0
259 random_battery[rows, 2 * bidx + 1] = x
260 random_policy[rows, pidx] = x
261 design = np.column_stack((fixed, random_battery, random_policy))
262 penalty = np.zeros(design.shape[1])
263 penalty[2 : 2 + len(features)] = lambda_fixed
264 penalty[fixed.shape[1] : fixed.shape[1] + random_battery.shape[1]] = lambda_battery
265 penalty[fixed.shape[1] + random_battery.shape[1] :] = lambda_policy
266 lhs = design.T @ design
267 lhs.flat[:: lhs.shape[0] + 1] += penalty + 1e-10
268 rhs = design.T @ frame["SOH_clean"].to_numpy(dtype=float)
269 try:
270     coef = np.linalg.solve(lhs, rhs)
271 except np.linalg.LinAlgError:
272     coef = np.linalg.lstsq(lhs, rhs, rcond=None)[0]
273 fitted = design @ coef
274 residual = frame["SOH_clean"].to_numpy(dtype=float) - fitted
275 residual_frame = pd.DataFrame({"battery_id": frame["battery_id"].to_numpy(), "cycle": frame["cycle"].to_numpy(), "residual": residual})
276 pairs = []
277 for _, group in residual_frame.groupby("battery_id", observed=True):
278     values = group.sort_values("cycle")["residual"].to_numpy()
279     if len(values) > 1:
280         pairs.append(np.corrcoef(values[:-1], values[1:])[0, 1])
281 info = {
282     "fixed_coef": coef[: fixed.shape[1]],
283     "feature_mean": means,
284     "feature_scale": scales,
285     "features": features,
286     "quadratic": quadratic,
287     "train_rmse": float(np.sqrt(np.mean(residual**2))),
288     "lag1_residual_correlation": float(np.nanmean(pairs)),
289     "n_policy": len(policies),
290     "n_battery": len(batteries),
291 }
292 return coef, info
293
294
295 def predict_hierarchical(info: dict[str, object], test_strategy: pd.DataFrame, cycles: np.ndarray) -> np.ndarray:
296     features = tuple(info["features"])
297     means = np.asarray(info["feature_mean"], dtype=float)
298     scales = np.asarray(info["feature_scale"], dtype=float)
299     fixed_coef = np.asarray(info["fixed_coef"], dtype=float)
300     predictions: list[dict[str, float | int | str]] = []
301     x = cycles.astype(float) / 200.0
302     for _, row in test_strategy.iterrows():
303         columns = [np.ones(len(x)), x]
304         for feature, mean, scale in zip(features, means, scales):
305             columns.append(np.repeat((float(row[feature]) - mean) / scale, len(x)) * x)
306         if bool(info["quadratic"]):
307             columns.append(x**2)
308         value = np.column_stack(columns) @ fixed_coef
309         for cycle, prediction in zip(cycles, value):
310             predictions.append({"policy": row["policy"], "cycle": int(cycle), "prediction": float(prediction)})
311     return pd.DataFrame(predictions)

```

```

1 """Data loading, trajectory utilities, metrics, and constrained extrapolation."""
2
3 from __future__ import annotations
4
5 from dataclasses import dataclass
6 from pathlib import Path
7 from typing import Iterable
8
9 import numpy as np
10 import pandas as pd
11
12 from .config import CONFIG, Q3Config
13
14
15 @dataclass
16 class BatteryRecord:
17     battery_id: int
18     policy: str
19     meta: pd.Series
20     cycles: pd.DataFrame
21     baseline: float

```

```

22 relative_soh: np.ndarray
23
24 def relative_at(self, cycle: int) -> float:
25     return float(self.relative_soh[cycle - 1])
26
27 def absolute_future(self, start: int = 151, end: int = 200) -> np.ndarray:
28     return self.baseline * self.relative_soh[start - 1 : end]
29
30
31 def load_records(project_root: Path) -> tuple[dict[int, BatteryRecord], pd.DataFrame, pd.DataFrame]:
32     data_dir = project_root / "data" / "processed" / "q1_cleaned"
33     meta = pd.read_csv(data_dir / "battery_summary_clean.csv")
34     cycles = pd.read_csv(data_dir / "cycle_train_clean.csv")
35     records: dict[int, BatteryRecord] = {}
36     for battery_id, frame in cycles.groupby("battery_id", sort=True):
37         row = meta.loc[meta["battery_id"].eq(battery_id)].iloc[0]
38         frame = frame.sort_values("cycle").reset_index(drop=True)
39         baseline = float(frame.loc[frame["cycle"].between(1, 5), "SOH_clean"].mean())
40         records[int(battery_id)] = BatteryRecord(
41             battery_id=int(battery_id),
42             policy=str(row["policy"]),
43             meta=row,
44             cycles=frame,
45             baseline=baseline,
46             relative_soh=frame["SOH_clean"].to_numpy(float) / baseline,
47         )
48     return records, meta, cycles
49
50
51 def complete_battery_ids(meta: pd.DataFrame) -> list[int]:
52     return sorted(meta.loc[meta["prediction_test"].eq(0), "battery_id"].astype(int).tolist())
53
54
55 def slope(values: np.ndarray, cycles: np.ndarray | None = None) -> float:
56     values = np.asarray(values, dtype=float)
57     if cycles is None:
58         cycles = np.arange(1, len(values) + 1, dtype=float)
59     else:
60         cycles = np.asarray(cycles, dtype=float)
61     good = np.isfinite(values) & np.isfinite(cycles)
62     if good.sum() < 2:
63         return 0.0
64     x = cycles[good]
65     y = values[good]
66     xc = x - x.mean()
67     denom = float(xc @ xc)
68     return 0.0 if denom <= 0 else float(xc @ (y - y.mean()) / denom)
69
70
71 def robust_slope_scale(slopes: Iterable[float]) -> float:
72     values = np.asarray(list(slopes), dtype=float)
73     values = values[np.isfinite(values)]
74     if values.size == 0:
75         return 1e-8
76     median = float(np.median(values))
77     scale = 1.4826 * float(np.median(np.abs(values - median)))
78     if scale < 1e-8:
79         scale = max(float(np.std(values, ddof=1)) if values.size > 1 else 0.0, 1e-8)
80     return scale
81
82
83 def fit_power_law(
84     cycles: np.ndarray,
85     relative_soh: np.ndarray,
86     config: Q3Config = CONFIG,
87 ) -> dict[str, float]:
88     t = np.asarray(cycles, dtype=float)
89     y = np.asarray(relative_soh, dtype=float)
90     good = np.isfinite(t) & np.isfinite(y)
91     t, y = t[good], y[good]
92     if t.size < 5:
93         return {"beta0": float(np.nanmean(y)), "a": 0.0, "p": 1.0, "sse": np.inf}
94     L = float(t.max())
95     weights = 1.0 + 2.0 * (t / L) ** 2
96     root_w = np.sqrt(weights)
97     best: dict[str, float] | None = None
98     for p in config.power_grid:
99         z = t**p
100         design = np.column_stack([np.ones_like(t), -z])
101         coef, *_ = np.linalg.lstsq(design * root_w[:, None], y * root_w, rcond=None)
102         beta0, a = float(coef[0]), float(coef[1])
103         if a < 0:
104             a = 0.0
105             beta0 = float(np.average(y, weights=weights))
106         pred = beta0 - a * z
107         sse = float(np.sum(weights * (y - pred) ** 2))
108         candidate = {"beta0": beta0, "a": a, "p": float(p), "sse": sse}
109         if best is None or sse < best["sse"]:
110             best = candidate
111     assert best is not None
112     return best
113
114
115 def predict_power_law(fit: dict[str, float], cycles: np.ndarray) -> np.ndarray:
116     t = np.asarray(cycles, dtype=float)
117     return fit["beta0"] - fit["a"] * t ** fit["p"]
118
119
120 def power_law_eol(fit: dict[str, float], baseline: float, config: Q3Config = CONFIG) -> tuple[float, str]:

```

```

121     threshold = 0.8 / baseline
122     beta0, a, p = fit["beta0"], fit["a"], fit["p"]
123     if not np.isfinite([beta0, a, p]).all() or a <= 0 or beta0 <= threshold or p <= 0:
124         return np.nan, "no_finite_intersection"
125     cycle = float(((beta0 - threshold) / a) ** (1.0 / p))
126     if not np.isfinite(cycle) or cycle > config.eol_max_cycle:
127         return np.nan, "beyond_5000"
128     if cycle <= 150:
129         return cycle, "before_or_at_observation"
130     return cycle, "finite_scenario"
131
132
133 def project_absolute_prediction(raw: np.ndarray, anchor: float, config: Q3Config = CONFIG) -> np.ndarray:
134     clipped = np.clip(np.asarray(raw, dtype=float), *config.soh_bounds)
135     return np.minimum.accumulate(np.concatenate([[float(anchor)], clipped]))[1:]
136
137
138 def prediction_metrics(y_true: np.ndarray, y_pred: np.ndarray) -> dict[str, float]:
139     residual = np.asarray(y_pred) - np.asarray(y_true)
140     return {
141         "rmse": float(np.sqrt(np.mean(residual**2))),
142         "mae": float(np.mean(np.abs(residual))),
143         "error_cycle200": float(residual[-1]),
144     }
145
146
147 def strategy_parameters(record: BatteryRecord) -> np.ndarray:
148     row = record.meta
149     return np.asarray([row.get("C1", np.nan), row.get("Q1", np.nan), row.get("C2", np.nan)], dtype=float)

```

```

1  """Auditable Q4 discrete Pareto and constrained single-exposure models."""
2
3  from __future__ import annotations
4
5  from dataclasses import dataclass
6  from pathlib import Path
7
8  import numpy as np
9  import pandas as pd
10
11  from q3_models.core import load_records
12
13
14  Q4_VERSION = "q4_smoke_v1"
15  SEED = 20260815
16  LAMBDA_GRID = np.array([0.0, 0.25, 0.5, 0.75, 1.0])
17
18
19  @dataclass(frozen=True)
20  class PolicyObservation:
21     policy: str
22     n_battery: int
23     time_mean: float
24     time_sd: float
25     loss_mean: float
26     loss_sd: float
27     late_slope_mean: float
28     c1: float
29     q1: float
30     c2: float
31     j: float
32     h: float
33     coordinate: tuple[float, float, float] | None
34
35
36  def _finite_mean(values: pd.Series) -> float:
37     values = pd.to_numeric(values, errors="coerce").dropna()
38     return float(values.mean()) if len(values) else float("nan")
39
40
41  def collect_policy_observations(project_root: Path) -> tuple[list[PolicyObservation], pd.DataFrame]:
42     records, meta, _ = load_records(project_root)
43     complete_ids = set(meta.loc[meta["prediction_test"].eq(0), "battery_id"].astype(int))
44     rows = []
45     observations: list[PolicyObservation] = []
46     for policy, group in meta.loc[meta["battery_id"].isin(complete_ids)].groupby("policy", sort=True):
47         battery_rows = []
48         for battery_id in sorted(group["battery_id"].astype(int)):
49             record = records[battery_id]
50             cycles = record.cycles
51             time_column = "chargetime_raw" if "chargetime_raw" in cycles.columns else "chargetime"
52             if time_column not in cycles.columns:
53                 raise KeyError("Q4 requires chargetime_raw (or legacy chargetime) in cleaned cycle data")
54             time_series = pd.to_numeric(cycles[time_column], errors="coerce")
55             time_value = float(time_series.mean())
56             loss_value = float(1.0 - record.relative_at(200))
57             late_values = record.relative_soh[150:200]
58             x = np.arange(151, 201, dtype=float)
59             xc = x - x.mean()
60             slope = float(xc @ (late_values - late_values.mean()) / (xc @ xc))
61             battery_rows.append({"battery_id": battery_id, "time": time_value,
62                                 "loss": loss_value, "late_slope_loss": max(0.0, -slope)})
63     values = pd.DataFrame(battery_rows)
64     first = group.iloc[0]
65     c1, q1, c2 = (float(first[col]) if pd.notna(first[col]) else np.nan for col in ("C1", "Q1", "C2"))
66     q = q1 / 100.0 if np.isfinite(q1) else np.nan
67     j = q * c1 + (0.8 - q) * c2 if np.isfinite([c1, q, c2]).all() else np.nan
68     h = 0.5 * (c1 * q**2 + c2 * (0.8**2 - q**2)) if np.isfinite([c1, q, c2]).all() else np.nan

```

```

69     coordinate = (c1, q1, c2) if np.isfinite([c1, q1, c2]).all() else None
70     observations.append(PolicyObservation(
71         policy=str(policy), n_battery=len(values), time_mean=float(values["time"].mean()),
72         time_sd=float(values["time"].std(ddof=1)) if len(values) > 1 else 0.0,
73         loss_mean=float(values["loss"].mean()),
74         loss_sd=float(values["loss"].std(ddof=1)) if len(values) > 1 else 0.0,
75         late_slope_mean=float(values["late_slope_loss"].mean()),
76         c1=c1, q1=q1, c2=c2, j=j, h=h, coordinate=coordinate,
77     ))
78     for row in battery_rows:
79         row.update({"policy": str(policy), "c1": c1, "q1": q1, "c2": c2, "j": j, "h": h})
80         rows.append(row)
81     return observations, pd.DataFrame(rows)
82
83
84 def observation_frame(observations: list[PolicyObservation]) -> pd.DataFrame:
85     return pd.DataFrame([obs.__dict__ for obs in observations])
86
87
88 def _normalise(values: np.ndarray) -> np.ndarray:
89     values = np.asarray(values, dtype=float)
90     lo, hi = np.nanmin(values), np.nanmax(values)
91     return np.zeros_like(values) if hi - lo < 1e-12 else (values - lo) / (hi - lo)
92
93
94 def pareto_mask(time: np.ndarray, loss: np.ndarray) -> np.ndarray:
95     time, loss = np.asarray(time, float), np.asarray(loss, float)
96     mask = np.ones(len(time), dtype=bool)
97     for i in range(len(time)):
98         dominated = (time <= time[i] + 1e-12) & (loss <= loss[i] + 1e-12)
99         strictly = (time < time[i] - 1e-12) | (loss < loss[i] - 1e-12)
100         mask[i] = not bool(np.any(dominated & strictly))
101     return mask
102
103
104 def choose_scalar(time: np.ndarray, loss: np.ndarray, policies: list[str], weight: float) -> int:
105     score = weight * _normalise(time) + (1.0 - weight) * _normalise(loss)
106     order = sorted(range(len(score)), key=lambda i: (score[i], loss[i], time[i], policies[i]))
107     return order[0]
108
109
110 def bootstrap_pareto(
111     frame: pd.DataFrame,
112     repetitions: int = 2000,
113     seed: int = SEED,
114     lambda_grid: np.ndarray | None = None,
115     loss_limits: tuple[float, ...] = (),
116 ) -> pd.DataFrame:
117     rng = np.random.default_rng(seed)
118     lambda_grid = LAMBDA_GRID if lambda_grid is None else np.asarray(lambda_grid, dtype=float)
119     policies = sorted(frame["policy"].unique())
120     records = {policy: frame.loc[frame["policy"].eq(policy)].reset_index(drop=True) for policy in policies}
121     rows = []
122     for rep in range(repetitions):
123         summary = []
124         for policy in policies:
125             data = records[policy]
126             idx = rng.integers(0, len(data), size=len(data))
127             sample = data.iloc[idx]
128             late_slope = float(sample["late_slope_loss"].mean()) if "late_slope_loss" in sample else np.nan
129             summary.append((policy, float(sample["time"].mean()), float(sample["loss"].mean()), late_slope))
130             t = np.array([row[1] for row in summary]); d = np.array([row[2] for row in summary])
131             front = pareto_mask(t, d)
132             choices = {w: summary[choose_scalar(t, d, policies, w)][0] for w in lambda_grid}
133             constrained_choices = {}
134             for limit in loss_limits:
135                 feasible = np.flatnonzero(d <= limit)
136                 constrained_choices[limit] = (
137                     min(feasible, key=lambda i: (t[i], d[i], policies[i])) if len(feasible) else None
138                 )
139             for index, ((policy, time_value, loss_value, late_slope), is_front) in enumerate(zip(summary, front)):
140                 rows.append({"version": Q4_VERSION, "replicate": rep, "policy": policy,
141                     "time": time_value, "loss": loss_value, "late_slope_loss": late_slope,
142                     "pareto": bool(is_front),
143                     **{f"selected_lambda_{w:.2f}": choices[w] == policy for w in lambda_grid},
144                     **{f"selected_loss_limit_{limit:.4f}": constrained_choices[limit] == index
145                         for limit in loss_limits}})
146             return pd.DataFrame(rows)
147
148
149 def fit_single_exposure(train: pd.DataFrame, exposure: str, lam: float) -> tuple[float, float, float, float]:
150     loss_column = "loss" if "loss" in train.columns else "loss_mean"
151     train = train.dropna(subset=[exposure, loss_column])
152     if len(train) < 2 or train[exposure].std(ddof=0) < 1e-8:
153         return float(train[loss_column].mean()), 0.0, float(train[exposure].mean()), 1.0
154     mean, scale = float(train[exposure].mean()), float(train[exposure].std(ddof=0))
155     z = (train[exposure].to_numpy(float) - mean) / scale
156     x = np.column_stack([np.ones(len(z)), z]); y = train[loss_column].to_numpy(float)
157     penalty = np.diag([0.0, lam]); coef = np.linalg.solve(x.T @ x + penalty, x.T @ y)
158     return float(coef[0]), float(coef[1]), mean, scale
159
160
161 def loso_single_exposure(
162     frame: pd.DataFrame,
163     exposure: str = "j",
164     ridge_grid: tuple[float, ...] = (0.01, 0.1, 1.0, 10.0),
165 ) -> pd.DataFrame:
166     usable = frame.dropna(subset=[exposure, "coordinate", "loss_mean"]).copy()
167     usable["coordinate_key"] = usable["coordinate"].astype(str)

```

```

168 rows = []
169 for held_out in sorted(usable["coordinate_key"].unique()):
170     train = usable.loc[usable["coordinate_key"].ne(held_out)]
171     test = usable.loc[usable["coordinate_key"].eq(held_out)]
172     best = None
173     for lam in ridge_grid:
174         intercept, slope, mean, scale = fit_single_exposure(train, exposure, lam)
175         if len(test) == 0 or scale < 1e-8:
176             pred = np.full(len(test), intercept)
177         else:
178             pred = intercept + slope * (test[exposure].to_numpy(float) - mean) / scale
179             rmse = float(np.sqrt(np.mean((pred - test["loss_mean"].to_numpy(float)) ** 2))) if len(test) else np.nan
180             candidate = (rmse, -lam, intercept, slope, mean, scale)
181             if best is None or candidate[2] < best[2]: best = candidate
182         assert best is not None
183         baseline_rmse = float(np.sqrt(np.mean((test["loss_mean"].to_numpy(float) - train["loss_mean"].mean()) ** 2))) if len(test) else np.
184         nan
185         rows.append({"version": Q4_VERSION, "exposure": exposure, "held_out_coordinate": held_out,
186                     "n_test_policy": len(test), "rmse": best[0], "lambda": -best[1],
187                     "constant_rmse": baseline_rmse, "improvement": baseline_rmse - best[0],
188                     "intercept": best[2], "slope": best[3], "train_mean": best[4],
189                     "train_scale": best[5], "validation_type": "coordinate_LOSO_extrapolation_pressure"})
190 return pd.DataFrame(rows)

```

附录 C AI 工具使用详情

本参赛队在竞赛中使用 AI 工具辅助完成以下环节：

1. 代码调试与运行环境配置；
2. 语言润色；
3. 数据处理与建模方案讨论。

核心建模思路、模型选择、数值结果核验与最终结论均由参赛队独立完成，AI 生成的代码与文字均已逐项人工审查与核实。详细交互过程见支撑材料”AI 工具使用详情.pdf”。